

UNIVERSIDADE PRESBITERIANA MACKENZIE

**CAINÃ FERNANDES GUIMARÃES DA SILVA
GABRIEL DE OLIVEIRA MELONI
HUMBERTO GUTTAU BRAVO
JIMMY PAIVA GOMES**

**SISTEMA DE RECOMENDAÇÃO DE MEDICAMENTOS BASEADO EM DADOS DO
UCI DRUG REVIEW: UMA ABORDAGEM COM TÉCNICAS DE ANÁLISE DE
DADOS E AGRUPAMENTO**

São Paulo
2026

CAINÃ FERNANDES GUIMARÃES DA SILVA
GABRIEL DE OLIVEIRA MELONI
HUMBERTO GUTTAU BRAVO
JIMMY PAIVA GOMES

**SISTEMA DE RECOMENDAÇÃO DE MEDICAMENTOS BASEADO EM DADOS DO
UCI DRUG REVIEW: UMA ABORDAGEM COM TÉCNICAS DE ANÁLISE DE
DADOS E AGRUPAMENTO**

Trabalho de projeto prático apresentado
ao curso de ciência de dados da
Universidade Presbiteriana Mackenzie,
como requisito parcial da matéria de
projeto aplicado III

São Paulo
2026

LISTA DE TABELAS

LISTA DE ILUSTRAÇÕES

Figura 1: Cronograma do projeto.....	9
Figura 2: Fluxo metodológico do projeto.....	14
Figura 3: Método do Cotovelo.....	23
Figura 4: Distribuição de Ratings.....	25
Figura 4: Visualização dos Clusters.....	27

SUMÁRIO

- 1. INTRODUÇÃO..... 6**
 - 1.1. CONTEXTO DO TRABALHO..... 6**
 - 1.2. MOTIVAÇÃO DO PROJETO.....7**
 - 1.3. JUSTIFICATIVA.....7**
 - 1.4. OBJETIVOS GERAIS E ESPECÍFICOS.....8**
 - 1.5. CRONOGRAMA..... 9**
 - 1.6. REPOSITÓRIO DO PROJETO..... 9**
- 2. REFERENCIAL TEÓRICO.....10**
- 3. METODOLOGIA.....13**
 - 3.1. DEFINIÇÃO DO PROBLEMA E OBJETIVOS..... 14**
 - 3.2. COLETA DE DADOS..... 15**
 - 3.3. PRÉ-PROCESSAMENTO E LIMPEZA DOS DADOS..... 16**
 - 3.4. DIVISÃO E ESTRUTURAÇÃO DOS DADOS.....16**
 - 3.5. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO..... 17**
 - 3.6. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO..... 17**
 - 3.7. AVALIAÇÃO DO DESEMPENHO..... 18**
 - 3.8. OTIMIZAÇÃO E AJUSTES..... 19**
 - 3.9. IMPLANTAÇÃO E MONITORAMENTO.....20**
- 4. RESULTADOS..... 21**
 - 4.1. MÉTRICAS DE AVALIAÇÃO..... 21**
 - 4.2. MÉTODO DO COTOVELO (ELBOW METHOD)..... 22**
 - 4.3. DISTRIBUIÇÃO DAS AVALIAÇÕES DOS USUÁRIOS..... 23**
 - 4.4. VISUALIZAÇÃO DOS CLUSTERS COM PCA.....25**
 - 4.5. COMPARAÇÃO COM BASELINES.....28**
 - 4.6. DISCUSSÃO DOS RESULTADOS..... 29**
- CONCLUSÃO.....32**
- REFERÊNCIAS..... 34**

1. INTRODUÇÃO

O avanço das tecnologias da informação e comunicação, aliado ao crescimento exponencial na geração e disponibilidade de dados, tem impulsionado o desenvolvimento de sistemas inteligentes voltados ao apoio à tomada de decisão em diversos setores, especialmente na área da saúde. Dentre essas soluções, destacam-se os sistemas de recomendação, que utilizam dados e algoritmos para fornecer sugestões personalizadas aos usuários, contribuindo para a melhoria da experiência e da assertividade nas escolhas (RICCI; ROKACH; SHAPIRA, 2015).

No contexto farmacêutico, observa-se que as farmácias desempenham um papel fundamental como ponto de acesso primário aos cuidados de saúde. No entanto, a facilidade de acesso a medicamentos, aliada à falta de orientação adequada, contribui para a prática recorrente da automedicação, frequentemente realizada de forma inadequada. De acordo com a Organização Mundial da Saúde, o uso irracional de medicamentos constitui um dos principais desafios globais em saúde pública, podendo ocasionar reações adversas, interações medicamentosas e agravamento de condições clínicas (OMS, 2002).

Diante desse cenário, surge a seguinte problemática: de que forma um sistema de recomendação pode auxiliar clientes de farmácia na escolha adequada de medicamentos, considerando sintomas apresentados e boas práticas farmacológicas? Parte-se da hipótese de que a aplicação de um sistema estruturado de recomendação, baseado em dados e diretrizes da área da saúde, pode contribuir significativamente para a promoção do uso racional de medicamentos, além de ampliar o acesso à informação de qualidade.

Adicionalmente, o presente projeto apresenta caráter extensionista, ao propor uma solução tecnológica voltada à resolução de uma demanda social relevante, relacionada ao acesso à informação em saúde. Nesse sentido, a pesquisa alinha-se aos Objetivos de Desenvolvimento Sustentável da Organização das Nações Unidas, especialmente ao ODS 3 — Saúde e Bem-Estar, que visa assegurar uma vida saudável e promover o bem-estar para todos, em todas as idades (ONU, 2015).

1.1. CONTEXTO DO TRABALHO

O presente estudo insere-se no contexto da transformação digital aplicada ao setor de saúde, com foco específico no ambiente farmacêutico, no qual se observa uma crescente demanda por soluções tecnológicas capazes de melhorar a qualidade do atendimento e a segurança dos usuários.

As farmácias, muitas vezes, constituem o primeiro ponto de contato da população com serviços de saúde, sobretudo em situações de baixa complexidade. Nesse ambiente, é comum que clientes busquem orientação para tratar sintomas diversos, frequentemente sem acompanhamento médico. Contudo, a ausência de suporte adequado pode levar à escolha incorreta de medicamentos.

Nesse cenário, os sistemas de recomendação apresentam-se como uma alternativa promissora, uma vez que permitem a análise de dados e a geração de sugestões personalizadas. Esses sistemas têm sido amplamente utilizados em setores como comércio eletrônico e serviços digitais, sendo adaptáveis ao contexto da saúde, desde que respeitadas as particularidades e limitações do domínio farmacêutico (AGGARWAL, 2016).

1.2. MOTIVAÇÃO DO PROJETO

A motivação para o desenvolvimento deste projeto está fundamentada na necessidade de mitigar os riscos associados à automedicação inadequada, prática amplamente disseminada na sociedade contemporânea. A dificuldade de interpretação de informações técnicas, aliada à ausência de orientação profissional em determinados contextos, contribui para decisões equivocadas por parte dos usuários.

Além disso, observa-se uma lacuna significativa entre a disponibilidade de informações sobre medicamentos e a capacidade dos indivíduos de utilizá-las de forma correta e segura. Nesse sentido, a utilização de tecnologias baseadas em dados surge como uma alternativa viável para reduzir essa lacuna, tornando a informação mais acessível, estruturada e aplicável.

Ademais, o desenvolvimento deste projeto também se justifica pelo potencial de aplicação prática dos conhecimentos adquiridos na área de ciência de dados e sistemas inteligentes, permitindo a construção de uma solução com impacto social relevante.

1.3. JUSTIFICATIVA

A relevância deste projeto pode ser compreendida sob três perspectivas principais: social, acadêmica e tecnológica.

Sob a perspectiva social, a proposta contribui diretamente para a promoção do uso racional de medicamentos, auxiliando na redução de riscos associados à automedicação inadequada. Ao oferecer recomendações baseadas em critérios estruturados, o sistema pode atuar como ferramenta de apoio à decisão, promovendo maior segurança e autonomia ao usuário.

No âmbito acadêmico, o projeto possibilita a integração de conceitos teóricos e práticos relacionados à ciência de dados, sistemas de recomendação e desenvolvimento de soluções aplicadas à saúde, contribuindo para a formação de profissionais capacitados para lidar com problemas complexos e multidisciplinares.

Do ponto de vista tecnológico, a proposta amplia as possibilidades de aplicação de sistemas de recomendação em áreas sensíveis, como a saúde, incentivando o desenvolvimento de soluções inovadoras que considerem aspectos éticos, técnicos e sociais.

Além disso, destaca-se o caráter extensionista do projeto, uma vez que a solução proposta busca atender uma necessidade concreta da sociedade, contribuindo para o alcance dos Objetivos de Desenvolvimento Sustentável, em especial o ODS 3 — Saúde e Bem-Estar, ao promover o acesso à informação de qualidade e práticas mais seguras no uso de medicamentos.

1.4. OBJETIVOS GERAIS E ESPECÍFICOS

O presente trabalho tem como objetivo desenvolver um sistema de recomendação de medicamentos que, a partir do diagnóstico de doenças informado pelos usuários, seja capaz de gerar sugestões fundamentadas em dados históricos de avaliações disponíveis no conjunto UCI ML Drug Review. Para tanto, a proposta baseia-se na análise integrada de informações como a condição clínica relatada, os medicamentos associados e as respectivas avaliações atribuídas pelos usuários, permitindo a identificação de padrões de relevância, similaridade e aceitação entre diferentes contextos de uso.


Nesse sentido, o sistema será concebido de modo a explorar técnicas de análise de dados e sistemas de recomendação, visando estruturar um modelo capaz de

correlacionar doenças a medicamentos potencialmente relevantes, a partir de evidências empíricas extraídas das experiências reportadas pelos próprios usuários. Adicionalmente, pretende-se incorporar critérios de consistência, frequência e qualidade das avaliações, com o objetivo de aprimorar a confiabilidade das recomendações e possibilitar a identificação de medicamentos que apresentem maior potencial de priorização em processos de aquisição no contexto farmacêutico.

Destaca-se que a solução proposta não tem como finalidade substituir a orientação de profissionais da saúde, mas sim atuar como instrumento complementar de apoio à tomada de decisão, contribuindo para a ampliação do acesso à informação e para a promoção do uso mais consciente de medicamentos. Dessa forma, o projeto também se alinha aos princípios do Objetivo de Desenvolvimento Sustentável 3 — Saúde e Bem-Estar, ao buscar fomentar práticas que favoreçam a qualidade de vida e o bem-estar da população.

1.5. CRONOGRAMA

Figura 1: Cronograma do projeto



Fonte: Autoral

1.6. REPOSITÓRIO DO PROJETO

Para o projeto, foi disponibilizado o seguinte repositório no github: [Repositório](#)

2. REFERENCIAL TEÓRICO

Os sistemas de recomendação têm se consolidado como ferramentas fundamentais no contexto da análise de dados, sendo amplamente utilizados para auxiliar usuários na tomada de decisão em diferentes domínios, como comércio eletrônico, plataformas de streaming e serviços digitais. Esses sistemas têm como principal objetivo oferecer sugestões personalizadas a partir da análise de grandes volumes de dados, considerando preferências, comportamentos e padrões históricos dos usuários (RICCI; ROKACH; SHAPIRA, 2015). Ao reduzir a sobrecarga informacional e aumentar a relevância das recomendações, tais sistemas contribuem diretamente para a melhoria da experiência do usuário e para a eficiência dos processos decisórios.

A estruturação de sistemas de recomendação pode ocorrer por meio de diferentes abordagens metodológicas. A filtragem colaborativa, uma das mais tradicionais, baseia-se na ideia de que usuários com comportamentos semelhantes tendem a compartilhar preferências. Dessa forma, recomendações são geradas a partir da análise de interações entre usuários e itens, permitindo inferir novas preferências com base em padrões coletivos (SARWAR et al., 2001). Por outro lado, a filtragem baseada em conteúdo utiliza características específicas dos itens para recomendar alternativas semelhantes às já consumidas pelo usuário, sendo especialmente útil em contextos com menor volume de dados históricos (AGGARWAL, 2016).

Além dessas abordagens, modelos híbridos têm sido amplamente explorados com o objetivo de superar limitações individuais, como o problema de inicialização a frio (*cold start*) e a esparsidade de dados. Conforme destacado por BURKE (2002), a combinação de diferentes técnicas permite aumentar a robustez dos sistemas de recomendação, proporcionando melhores resultados em cenários complexos e heterogêneos.

No contexto da saúde, a aplicação de sistemas de recomendação apresenta desafios adicionais, uma vez que envolve dados sensíveis e decisões que podem impactar diretamente a qualidade de vida dos indivíduos. Ainda assim, o uso dessas tecnologias tem crescido significativamente, especialmente como ferramentas de apoio à decisão. De acordo com SHICKEL et al. (2017), a incorporação de técnicas de

aprendizado de máquina na área da saúde possibilita o desenvolvimento de soluções capazes de analisar grandes volumes de dados e fornecer informações relevantes para usuários e profissionais.

Nesse cenário, destaca-se a importância da utilização responsável dessas tecnologias, considerando aspectos como segurança, confiabilidade e transparência. Sistemas de recomendação aplicados à saúde não devem substituir a atuação de profissionais qualificados, mas sim atuar como instrumentos complementares que auxiliem na interpretação de informações e na tomada de decisões mais informadas.

A crescente digitalização dos serviços e o aumento da participação dos usuários na geração de conteúdo têm contribuído para a formação de bases de dados ricas e diversificadas. O conjunto de dados UCI ML Drug Review insere-se nesse contexto, reunindo informações sobre doenças, medicamentos, avaliações numéricas e comentários textuais fornecidos por usuários. Esse tipo de dataset permite explorar relações entre condições clínicas e tratamentos a partir de experiências reais, possibilitando a construção de modelos baseados em evidências empíricas.

A utilização de dados provenientes de avaliações de usuários apresenta vantagens e limitações. Por um lado, tais dados refletem a experiência prática dos indivíduos, incluindo percepções sobre eficácia, efeitos colaterais e satisfação com o tratamento. Por outro lado, essas informações possuem natureza subjetiva e podem ser influenciadas por fatores individuais, o que exige cautela na interpretação dos resultados (DREW; KELLOGG; LEE, 2020). Dessa forma, é fundamental compreender que tais sistemas fornecem suporte informacional, não substituindo evidências clínicas.

Além das informações estruturadas, como notas e categorias, o dataset também inclui dados textuais que podem ser explorados por meio de técnicas de processamento de linguagem natural (Natural Language Processing — NLP). Essas técnicas permitem analisar grandes volumes de texto não estruturado, identificando padrões semânticos, sentimentos e tópicos relevantes. Segundo MINER et al. (2012), a utilização de NLP amplia significativamente a capacidade analítica dos sistemas de recomendação, tornando-os mais sensíveis ao contexto e às nuances das avaliações.

Técnicas como vetorização de texto, incluindo métodos como TF-IDF, possibilitam a transformação de dados textuais em representações numéricas, permitindo sua utilização em modelos computacionais. De acordo com MANNING, RAGHAVAN e SCHÜTZE (2008), essas abordagens são fundamentais para a análise de

informações textuais em larga escala, sendo amplamente utilizadas em sistemas de recuperação de informação e aprendizado de máquina.

Outro componente relevante na análise de dados é a utilização de técnicas de aprendizado não supervisionado, especialmente algoritmos de agrupamento (*clustering*). Esses métodos permitem identificar estruturas ocultas nos dados, agrupando elementos com características semelhantes sem a necessidade de rótulos previamente definidos (HAN; KAMBER; PEI, 2012). No contexto deste projeto, o uso de *clustering* pode contribuir para a identificação de padrões entre doenças, medicamentos e avaliações, possibilitando a segmentação de grupos com comportamentos semelhantes.

A qualidade dos agrupamentos gerados por algoritmos de *clustering* deve ser avaliada por meio de métricas adequadas. Nesse contexto, destaca-se o *Silhouette Score*, proposto por ROUSSEEUW (1987), que mede simultaneamente a coesão interna dos grupos e a separação entre clusters distintos. Essa métrica baseia-se na comparação entre a distância média de um elemento em relação aos demais elementos do mesmo grupo e a distância em relação ao grupo mais próximo.

Os valores do *Silhouette Score* variam entre -1 e 1, sendo que valores próximos de 1 indicam agrupamentos bem definidos, valores próximos de zero sugerem sobreposição entre grupos e valores negativos indicam possíveis erros na alocação dos elementos. Conforme discutido por TAN, STEINBACH e KUMAR (2005), essa métrica é amplamente utilizada para validar modelos de agrupamento e auxiliar na determinação do número ideal de clusters.

No contexto deste projeto, a utilização do *Silhouette Score* é fundamental para garantir a qualidade dos agrupamentos utilizados no sistema de recomendação. A identificação de clusters bem definidos permite estruturar recomendações mais consistentes, baseadas em padrões reais observados nos dados, contribuindo para a robustez do modelo proposto.

Além da construção e validação dos modelos, é importante considerar as métricas de avaliação utilizadas em sistemas de recomendação. Indicadores como precisão, recall e erro médio quadrático (RMSE) são amplamente empregados para medir o desempenho dos modelos, permitindo avaliar sua capacidade de prever preferências e gerar recomendações relevantes (HERLOCKER et al., 2004). A escolha adequada dessas métricas é essencial para garantir a confiabilidade dos resultados.

Do ponto de vista social, o desenvolvimento de sistemas baseados em dados na área da saúde está alinhado a iniciativas globais voltadas à melhoria da qualidade de

vida da população. Os Objetivos de Desenvolvimento Sustentável propostos pela Organização das Nações Unidas destacam a importância de promover o acesso à saúde e ao bem-estar por meio de soluções inovadoras e acessíveis (ONU, 2015).

Nesse mesmo sentido, a Organização Mundial da Saúde enfatiza a necessidade de promover o uso racional de medicamentos, destacando que decisões informadas são fundamentais para evitar riscos e garantir tratamentos eficazes (OMS, 2002). A utilização de sistemas de recomendação pode contribuir para esse objetivo ao ampliar o acesso à informação de qualidade.

Adicionalmente, questões éticas relacionadas ao uso de dados devem ser consideradas no desenvolvimento de sistemas inteligentes. Aspectos como privacidade, transparência e responsabilidade são fundamentais para garantir a confiança dos usuários. Conforme discutido por FLORIDI et al. (2018), o desenvolvimento de sistemas baseados em inteligência artificial deve seguir princípios éticos que assegurem a proteção dos indivíduos e a utilização responsável das tecnologias.

Dessa forma, a integração entre sistemas de recomendação, técnicas de processamento de linguagem natural, métodos de agrupamento e métricas de validação, como o *Silhouette Score*, constitui uma abordagem robusta e coerente com os objetivos deste projeto. A utilização do dataset UCI ML Drug Review, aliada a essas técnicas, possibilita o desenvolvimento de uma solução capaz de apoiar a tomada de decisão dos usuários, promovendo o acesso à informação e contribuindo para o uso mais consciente de medicamentos.

3. METODOLOGIA

Nesta seção, apresenta-se o delineamento metodológico adotado para o desenvolvimento do sistema de recomendação de medicamentos proposto neste trabalho. A metodologia foi estruturada de forma sistemática, seguindo um fluxo sequencial de etapas que compreendem a definição do problema, coleta e tratamento dos dados, modelagem, avaliação e aplicação do modelo.

A abordagem metodológica fundamenta-se em técnicas de ciência de dados e aprendizado de máquina, com ênfase em métodos de aprendizado não supervisionado. A escolha dessa abordagem deve-se à natureza do problema, que não dispõe de rótulos explícitos de saída, exigindo a identificação de padrões latentes nos dados (HAN; KAMBER; PEI, 2012).

Adicionalmente, a metodologia está alinhada aos princípios dos sistemas de recomendação baseados em dados, os quais buscam reduzir a sobrecarga informacional e apoiar a tomada de decisão por meio da análise de grandes volumes de dados (RICCI; ROKACH; SHAPIRA, 2015).

A Figura 2 apresenta o fluxograma das etapas metodológicas adotadas no projeto.

Figura 2: Fluxo metodológico do projeto



Fonte: Autoral

As subseções a seguir detalham cada uma das etapas.

3.1. DEFINIÇÃO DO PROBLEMA E OBJETIVOS

A definição do problema constitui uma etapa fundamental no desenvolvimento de sistemas baseados em dados, pois orienta todas as decisões metodológicas subsequentes (AGGARWAL, 2016).

No contexto deste trabalho, o problema central consiste na dificuldade enfrentada por usuários na escolha adequada de medicamentos, especialmente em cenários de automedicação. Tal contexto é amplamente discutido pela Organização Mundial da Saúde, que destaca o uso irracional de medicamentos como um dos principais desafios de saúde pública global (OMS, 2002).

Dessa forma, este projeto propõe o desenvolvimento de um sistema de recomendação capaz de sugerir medicamentos com base em dados históricos de

avaliações de usuários, considerando critérios como eficácia percebida, frequência de uso e relevância.

O objetivo geral consiste em desenvolver um modelo de recomendação baseado no dataset UCI ML Drug Review, utilizando técnicas de análise de dados e aprendizado não supervisionado.

Como objetivos específicos, destacam-se:

- Estruturar e preparar dados para modelagem;
- Identificar padrões de desempenho entre medicamentos;
- Desenvolver um modelo de agrupamento;
- Implementar uma lógica de recomendação baseada em clusters;
- Avaliar a qualidade dos agrupamentos gerados.

Essa abordagem está alinhada à aplicação de sistemas de recomendação no contexto da saúde, que devem atuar como ferramentas de apoio à decisão, e não como substitutos da atuação profissional (SHICKEL et al., 2017).

3.2. COLETA DE DADOS

Os dados utilizados foram obtidos a partir do *dataset* UCI ML Drug Review, amplamente utilizado em pesquisas acadêmicas e disponibilizado publicamente na plataforma Kaggle.

Esse *dataset* contém mais de 160 mil registros de avaliações de usuários sobre medicamentos, incluindo variáveis estruturadas e não estruturadas. Segundo Drew, Kellogg e Lee (2020), bases de dados provenientes de avaliações reais apresentam elevado valor analítico, pois refletem experiências práticas dos usuários.

As variáveis utilizadas incluem:

- Nome do medicamento;
- Condição tratada;
- Avaliação numérica;
- Número de votos úteis;
- Comentários textuais.

A escolha deste dataset justifica-se por sua riqueza informacional e representatividade, permitindo a construção de modelos baseados em evidências empíricas.

Além disso, a utilização de dados reais está alinhada com práticas contemporâneas de ciência de dados, que priorizam análises baseadas em comportamento observado (MANNING; RAGHAVAN; SCHÜTZE, 2008).

3.3. PRÉ-PROCESSAMENTO E LIMPEZA DOS DADOS

O pré-processamento é uma etapa crítica em projetos de ciência de dados, sendo responsável por garantir a qualidade e a consistência dos dados utilizados (HAN; KAMBER; PEI, 2012).

Inicialmente, foram removidos registros com valores ausentes na variável *condition*, por se tratar de uma variável essencial para o funcionamento do sistema. A presença de dados incompletos pode comprometer a confiabilidade do modelo e introduzir vieses na análise.

Posteriormente, foi realizada uma análise exploratória dos dados (EDA), que tem como objetivo compreender a distribuição das variáveis e identificar padrões relevantes (TAN; STEINBACH; KUMAR, 2005).

A análise da variável *rating* revelou uma distribuição polarizada, característica comum em sistemas de avaliação online, nos quais usuários tendem a avaliar apenas experiências extremamente positivas ou negativas.

Além disso, foram analisadas as frequências das condições e a distribuição dos medicamentos, permitindo identificar padrões de uso e relevância.

3.4. DIVISÃO E ESTRUTURAÇÃO DOS DADOS

Como o problema abordado utiliza aprendizado não supervisionado, não há necessidade de divisão tradicional em conjuntos de treino e teste.

Em vez disso, foi realizada uma transformação estrutural dos dados por meio de agregação, convertendo o dataset em uma representação centrada nos medicamentos.

Essa etapa é conhecida como feature engineering, sendo fundamental para melhorar a qualidade dos modelos (AGGARWAL, 2016).

Foram criadas as seguintes variáveis:

- Média das avaliações (indicador de qualidade percebida);
- Média de utilidade (indicador de relevância social);
- Número de condições tratadas (indicador de abrangência).

Essa abordagem permite representar cada medicamento como um vetor numérico, possibilitando a aplicação de algoritmos de agrupamento.

3.5. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO

O algoritmo escolhido para a modelagem foi o K-Means, um dos métodos mais utilizados em aprendizado não supervisionado para tarefas de agrupamento (clustering).

Segundo Han, Kamber e Pei (2012), o K-Means é adequado para identificar grupos homogêneos em dados numéricos, destacando-se por ser eficiente e escalável para grandes volumes de dados.

A escolha deste algoritmo também se justifica pela natureza do problema, que busca identificar perfis de desempenho e similaridade entre os medicamentos analisados.

Antes da aplicação do modelo, foi realizada a padronização dos dados utilizando o StandardScaler (ferramenta da biblioteca Python Scikit-Learn), técnica que transforma as variáveis para uma mesma escala.

Essa etapa de pré-processamento é essencial, pois o algoritmo K-Means utiliza a distância euclidiana como métrica de similaridade, sendo, portanto, altamente sensível à magnitude das variáveis (TAN; STEINBACH; KUMAR, 2005).

3.6. SELEÇÃO E IMPLEMENTAÇÃO DO ALGORITMO

O treinamento do modelo foi realizado por meio da aplicação do algoritmo K-Means sobre os dados previamente tratados e padronizados. Como o K-Means requer a definição prévia do número de clusters (K), tornou-se necessário empregar uma técnica adequada para determinar esse parâmetro de forma fundamentada.

Para isso, foi utilizado o Método do Cotovelo (Elbow Method), uma abordagem amplamente adotada na literatura para identificação do número ideal de agrupamentos (HAN; KAMBER; PEI, 2012).

O método baseia-se na análise da inércia, também conhecida como *Within-Cluster Sum of Squares (WCSS)*, que mede a soma das distâncias quadráticas entre cada ponto de dados e o centroide do cluster ao qual pertence. De forma geral, a inércia pode ser definida pela seguinte equação:

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

- k representa o número de clusters;
- C_i corresponde ao conjunto de pontos pertencentes ao cluster i ;
- x representa cada ponto de dados;
- μ_i é o centróide do cluster i .

À medida que o número de clusters aumenta, a inércia tende a diminuir, uma vez que os grupos se tornam mais específicos e compactos. No entanto, essa redução não ocorre de maneira linear. Inicialmente, há uma queda acentuada na inércia, seguida por uma redução mais suave.

O “cotovelo” do gráfico — ponto em que a taxa de redução da inércia começa a diminuir significativamente — indica o número ideal de clusters, equilibrando a complexidade do modelo e a qualidade do agrupamento.

No presente estudo, a análise do gráfico evidenciou que esse ponto ocorre em $K = 10$, indicando que esse número de clusters proporciona uma segmentação adequada dos medicamentos sem introduzir complexidade desnecessária ao modelo.

Com base nessa definição, o algoritmo K-Means foi treinado com quatro clusters, permitindo a identificação de diferentes perfis de desempenho entre os medicamentos analisados.

3.7. AVALIAÇÃO DO DESEMPENHO

A avaliação do modelo de agrupamento foi realizada por meio do Silhouette Score, uma métrica amplamente utilizada para validar a qualidade de clusters em problemas de aprendizado não supervisionado (ROUSSEEUW, 1987).

Diferentemente da inércia, que avalia apenas a coesão interna dos clusters, o Silhouette Score considera simultaneamente dois aspectos fundamentais:

- Coesão: quão próximos estão os pontos dentro do mesmo cluster;
- Separação: quão distantes estão os clusters entre si.

Para cada ponto i , o coeficiente de silhueta é definido como:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

onde:

- $a(i)$: distância média entre o ponto i e os demais pontos do mesmo cluster;

- $b(i)$: menor distância média entre o ponto i e os pontos de outro cluster mais próximo.

O valor de $s(i)$ varia entre -1 e 1:

- valores próximos de 1 indicam que o ponto está bem alocado;
- valores próximos de 0 indicam sobreposição entre clusters;
- valores negativos indicam possível classificação incorreta.

A execução do modelo no ambiente Python obteve um Silhouette Score médio de aproximadamente 0,282, indicando que os clusters gerados são razoavelmente bem definidos, embora exista certa sobreposição entre alguns grupos.

Esse resultado é considerado aceitável para dados reais e heterogêneos processados neste experimento, especialmente no contexto de avaliações subjetivas de usuários, como é o caso deste dataset (TAN; STEINBACH; KUMAR, 2005).

Além da avaliação quantitativa utilizando métricas puras, a exploração visual dos dados foi conduzida através da técnica de Análise de Componentes Principais (PCA). Para isso, importou-se a classe PCA do módulo `sklearn.decomposition`.

A aplicação do PCA em Python permitiu reduzir a dimensionalidade vetorial dos medicamentos, projetando os dados em um espaço bidimensional (gráfico de dispersão/scatter plot gerado via `matplotlib`). Essa visualização corroborou os cálculos de silhueta, possibilitando observar a separação gráfica dos clusters e a identificação de padrões estruturais no comportamento das variáveis.

3.8. OTIMIZAÇÃO E AJUSTES

Após a avaliação inicial do modelo, foram implementadas melhorias com o objetivo de aumentar a relevância e a robustez das recomendações geradas.

Uma das principais estratégias adotadas foi a identificação do chamado “cluster premium”, definido como aquele que apresenta a maior média de avaliação (*avg_rating*). Essa abordagem baseia-se na premissa de que medicamentos com

avaliações consistentemente altas tendem a representar melhores opções sob a perspectiva dos usuários.

A lógica de recomendação foi então estruturada da seguinte forma:

1. Identificação do cluster com maior média de avaliação;
2. Filtragem dos medicamentos associados à condição informada;
3. Seleção dos medicamentos pertencentes ao cluster premium;
4. Ordenação com base em utilidade (*usefulCount*) e avaliação;
5. Retorno das melhores recomendações.

Adicionalmente, foi implementada uma estratégia de fallback, que consiste em retornar os melhores medicamentos disponíveis independentemente do cluster, caso não existam itens do cluster premium para determinada condição.

Essa abordagem garante que o sistema mantenha sua funcionalidade mesmo em cenários com baixa representatividade de dados, aumentando sua aplicabilidade prática. Segundo Ricci, Rokach e Shapira (2015), a adoção de estratégias híbridas e mecanismos de fallback é essencial para melhorar a robustez dos sistemas de recomendação.

3.9. IMPLANTAÇÃO E MONITORAMENTO

A etapa final do processo metodológico consiste na aplicação prática do modelo desenvolvido, possibilitando sua utilização como ferramenta de apoio à decisão.

O sistema de recomendação foi projetado para operar de forma dinâmica, recebendo como entrada a condição clínica informada pelo usuário e retornando uma lista ordenada de medicamentos recomendados.

O fluxo de funcionamento do sistema pode ser descrito em cinco etapas principais:

1. Identificação da condição clínica;
2. Filtragem dos medicamentos associados;
3. Classificação com base nos clusters gerados;
4. Priorização dos medicamentos de maior desempenho;
5. Geração da lista final de recomendações.

Do ponto de vista operacional, o modelo pode ser integrado a diferentes plataformas, como aplicações web, dashboards analíticos ou sistemas de apoio farmacêutico.

Entretanto, conforme destacado por Goodfellow, Bengio e Courville (2016), modelos de aprendizado de máquina não devem ser considerados estáticos. Dessa

forma, recomenda-se a implementação de um processo contínuo de monitoramento, que inclua:

- atualização periódica da base de dados;
- reavaliação do número de clusters;
- análise de desempenho ao longo do tempo;
- ajustes na lógica de recomendação.

Esse processo é fundamental para garantir a adaptabilidade do sistema a mudanças nos dados e preservar a qualidade das recomendações.

4. RESULTADOS

Os resultados obtidos no desenvolvimento do sistema de recomendação demonstram que a aplicação de técnicas de aprendizado de máquina e análise de dados foi capaz de identificar padrões relevantes nas avaliações de medicamentos realizadas pelos usuários. O modelo desenvolvido utilizou técnicas de clusterização com o algoritmo K-Means, análise exploratória de dados e redução de dimensionalidade com PCA, permitindo agrupar medicamentos com características semelhantes a partir das avaliações textuais e numéricas presentes no dataset.

4.1. MÉTRICAS DE AVALIAÇÃO

Para avaliar a qualidade dos agrupamentos gerados pelo algoritmo K-Means, foi utilizada a métrica Silhouette Score, responsável por medir o grau de separação entre os clusters formados.

O valor obtido foi aproximadamente:

- **Silhouette Score = 0,282**

Esse resultado indica uma separação moderada entre os grupos identificados pelo algoritmo. Embora os clusters não estejam completamente isolados, o desempenho pode ser considerado satisfatório para uma prova de conceito baseada em dados textuais e avaliações subjetivas de usuários.

Valores próximos de 1 representam clusters altamente separados e bem definidos, enquanto valores próximos de 0 indicam sobreposição entre grupos. Dessa forma, o valor encontrado demonstra que o modelo conseguiu identificar padrões relevantes mesmo diante da alta variabilidade presente nas reviews.

Além disso, a utilização de técnicas de padronização dos dados contribuiu significativamente para melhorar a estabilidade do algoritmo, reduzindo o impacto de variáveis com escalas diferentes.

4.2. MÉTODO DO COTOVELO (ELBOW METHOD)

Para determinar a quantidade ideal de clusters utilizada no algoritmo K-Means, foi aplicado o Método do Cotovelo (Elbow Method), uma das técnicas mais utilizadas em problemas de clusterização não supervisionada.

O método consiste em executar o algoritmo K-Means para diferentes valores de K (quantidade de clusters) e calcular, para cada execução, a inércia do modelo. A inércia representa a soma das distâncias quadráticas entre cada ponto e o centróide do cluster ao qual pertence. Em outras palavras, essa métrica mede o nível de compactação dos agrupamentos formados.

Quanto menor o valor da inércia, mais próximos os dados estão de seus respectivos centroides, indicando clusters mais homogêneos. Entretanto, aumentar excessivamente o número de clusters pode gerar sobreajuste e reduzir a capacidade de generalização do modelo. Por esse motivo, o Método do Cotovelo busca encontrar um ponto de equilíbrio entre simplicidade e qualidade dos agrupamentos.

Durante os testes realizados no projeto, foram avaliados diferentes valores de K, permitindo observar o comportamento da curva de inércia. Inicialmente, verificou-se uma redução acentuada da inércia à medida que novos clusters eram adicionados. Contudo, após determinado ponto, essa redução passou a ocorrer de forma menos significativa, indicando que o aumento do número de grupos deixava de gerar melhorias relevantes no modelo.

O ponto de inflexão da curva foi identificado próximo ao valor:

- $K = 10$


Esse resultado indica que a divisão da base de dados em dez clusters apresentou o melhor equilíbrio entre separação dos grupos e eficiência computacional.

A escolha adequada do número de clusters foi fundamental para garantir que o modelo conseguisse representar corretamente os diferentes padrões de comportamento existentes nas avaliações dos usuários. Uma quantidade insuficiente de clusters poderia agrupar medicamentos muito distintos em um mesmo grupo, enquanto um número

excessivo de clusters poderia fragmentar demasiadamente os dados, dificultando a interpretação dos resultados.

Além disso, a aplicação do Método do Cotovelo contribuiu diretamente para aumentar a confiabilidade do sistema de recomendação, permitindo que os agrupamentos gerados pelo algoritmo apresentassem maior coerência estatística.

Figura 3: Método do Cotovelo



Fonte: Autoral

A Figura 3 apresenta o gráfico gerado pelo Método do Cotovelo, utilizado para identificar o número ideal de clusters no algoritmo K-Means. Observa-se que a redução da inércia ocorre de forma acentuada nos primeiros valores de K, indicando melhora significativa na compactação dos grupos. Entretanto, após aproximadamente K = 10, a curva passa a apresentar comportamento mais estável, demonstrando que o aumento adicional do número de clusters gera ganhos reduzidos no desempenho do modelo. Dessa forma, o valor K = 10 foi definido como o mais adequado para representar os padrões existentes no conjunto de dados analisados.

4.3. DISTRIBUIÇÃO DAS AVALIAÇÕES DOS USUÁRIOS

A análise da distribuição das avaliações dos usuários representou uma etapa fundamental para compreensão do comportamento presente no conjunto de dados utilizado no sistema de recomendação. Essa análise permitiu identificar padrões

importantes relacionados à satisfação dos usuários, frequência de avaliações e possíveis tendências de comportamento associadas aos medicamentos avaliados.

Inicialmente, foi realizado o estudo estatístico das notas atribuídas pelos usuários aos medicamentos presentes na base de dados. Os resultados demonstraram uma distribuição fortemente polarizada, caracterizada pela elevada concentração de avaliações nos extremos da escala, principalmente nas notas 1 e 10.

Esse comportamento indica que os usuários tendem a registrar avaliações principalmente quando possuem experiências muito positivas ou muito negativas em relação ao tratamento utilizado. Em muitos casos, usuários satisfeitos relatam melhora significativa dos sintomas e eficácia do medicamento, enquanto avaliações negativas normalmente estão associadas à presença de efeitos colaterais, baixa eficácia terapêutica ou dificuldades durante o tratamento.

Além disso, observou-se que medicamentos com maior quantidade de avaliações também apresentavam maior volume de reviews textuais detalhadas, tornando-se elementos importantes para o treinamento e interpretação do sistema de recomendação.

A distribuição identificada também demonstra uma característica comum em plataformas de avaliações online: a predominância de opiniões extremas. Usuários com experiências moderadas tendem a avaliar menos frequentemente, enquanto experiências muito positivas ou negativas incentivam maior participação.

Do ponto de vista computacional, essa polarização influencia diretamente o comportamento dos algoritmos de recomendação e clusterização, pois cria regiões de alta densidade nos extremos da distribuição das notas. Isso reforça a necessidade de utilização de técnicas complementares, como mineração de texto e análise semântica, capazes de capturar nuances mais complexas presentes nos reviews escritos pelos usuários.

Outro aspecto relevante observado durante a análise foi a existência de possíveis relações entre o número de votos úteis (“usefulCount”) e a qualidade das avaliações. Reviews mais detalhadas e descritivas tendiam a receber maior quantidade de votos úteis, indicando que os usuários valorizam informações mais completas sobre eficácia, efeitos adversos e experiência geral com os medicamentos.

Além disso, a análise exploratória permitiu identificar:


- Presença de medicamentos altamente populares;
- Grande variabilidade entre avaliações;
- Existência de reviews longas e detalhadas;

- Possíveis padrões de comportamento entre grupos de usuários;
- Relações entre satisfação e engajamento nas avaliações.

Esses resultados foram fundamentais para orientar as etapas seguintes do projeto, principalmente no desenvolvimento do modelo de clusterização e na interpretação dos agrupamentos gerados pelo algoritmo K-Means.

A compreensão do comportamento das avaliações também contribuiu para validar a relevância da base de dados utilizada, demonstrando que os reviews possuem riqueza informacional suficiente para aplicação de técnicas de aprendizado de máquina em sistemas de recomendação voltados à área da saúde.

Figura 4: Distribuição de Ratings



Fonte: Autoral

A Figura 4 apresenta a distribuição das notas atribuídas pelos usuários aos medicamentos presentes no conjunto de dados analisados. Observa-se forte concentração de avaliações máximas, principalmente na nota 10, indicando elevado nível de satisfação em parte significativa dos tratamentos avaliados. Também é possível identificar presença considerável de avaliações mínimas, evidenciando experiências negativas associadas à eficácia dos medicamentos ou ocorrência de efeitos colaterais. Esse comportamento polarizado demonstra que as avaliações estão diretamente relacionadas às experiências subjetivas dos usuários, reforçando a importância da utilização de técnicas de mineração de dados e aprendizado de máquina para identificação de padrões mais complexos.

4.4. VISUALIZAÇÃO DOS CLUSTERS COM PCA

Com o objetivo de facilitar a interpretação visual dos agrupamentos gerados pelo algoritmo K-Means, foi aplicada a técnica PCA (Principal Component Analysis), amplamente utilizada em problemas de redução de dimensionalidade e visualização de dados multidimensionais.

O conjunto de dados utilizado no projeto possuía múltiplas variáveis numéricas e características extraídas dos reviews textuais dos usuários, tornando inviável a visualização direta dos agrupamentos em um espaço tradicional bidimensional. Dessa forma, a aplicação do PCA permitiu transformar os dados originais em componentes principais capazes de preservar a maior parte da variabilidade estatística presente na base.

A técnica PCA funciona projetando os dados em novos eixos ortogonais, chamados componentes principais, que representam as direções de maior variância dos dados. No contexto deste projeto, foram selecionados os dois primeiros componentes principais, permitindo representar visualmente os clusters em um gráfico bidimensional.

A utilização do PCA trouxe benefícios importantes para a análise dos resultados, pois possibilitou:

- Visualizar a separação entre os clusters;
- Identificar regiões de maior densidade de dados;
- Observar possíveis sobreposições entre grupos;
- Analisar padrões de similaridade entre medicamentos;
- Facilitar a interpretação do comportamento do algoritmo K-Means.

Os resultados obtidos demonstraram que determinados clusters apresentaram separação espacial mais evidente, indicando maior homogeneidade entre os elementos pertencentes ao mesmo grupo. Em contrapartida, alguns clusters apresentaram regiões parcialmente sobrepostas, revelando que certos medicamentos compartilham características semelhantes em relação às avaliações realizadas pelos usuários.

Esse comportamento era esperado, considerando a natureza subjetiva das reviews utilizadas no projeto. Medicamentos diferentes podem apresentar avaliações semelhantes dependendo do perfil do paciente, da condição clínica tratada e da experiência individual durante o uso do tratamento.

Além disso, observou-se que alguns grupos apresentavam maior dispersão espacial no gráfico PCA, sugerindo maior diversidade de padrões internos dentro do

mesmo cluster. Outros grupos, por sua vez, demonstraram maior compactação, indicando elevada similaridade entre os medicamentos agrupados.

A visualização dos clusters também contribuiu significativamente para validar os resultados obtidos anteriormente através do Silhouette Score e do Método do Cotovelo. Enquanto o Silhouette Score forneceu uma avaliação quantitativa da qualidade dos agrupamentos, o PCA permitiu uma análise visual complementar, tornando mais intuitiva a compreensão do comportamento do modelo.


Outro aspecto importante observado foi a capacidade do modelo em identificar estruturas relevantes mesmo diante de uma base de dados altamente heterogênea e composta por informações subjetivas. Isso demonstra que a combinação entre técnicas de clusterização e redução de dimensionalidade pode gerar resultados úteis em aplicações de sistemas de recomendação baseados em avaliações textuais.

A aplicação do PCA também evidenciou o potencial do sistema para futuras implementações mais avançadas, como:

- Sistemas híbridos de recomendação;
- Modelos supervisionados de classificação;
- Técnicas de embeddings semânticos;
- Redes neurais aplicadas à recomendação;
- Análise de similaridade entre usuários e medicamentos.

Dessa forma, a visualização dos clusters não apenas facilitou a interpretação dos resultados obtidos, mas também demonstrou a viabilidade prática da utilização de aprendizado de máquina em problemas relacionados à saúde digital e recomendação inteligente de tratamentos.

Figura 5: Visualização dos Clusters



Fonte: Autoral

A Figura 5 apresenta a representação visual dos clusters gerados pelo algoritmo K-Means após aplicação da técnica PCA para redução de dimensionalidade. Cada cor representa um agrupamento distinto de medicamentos com características semelhantes em relação às avaliações dos usuários. Observa-se que alguns clusters apresentam maior separação espacial, indicando grupos mais homogêneos, enquanto outros apresentam regiões parcialmente sobrepostas, demonstrando similaridade entre determinados padrões de comportamento. A visualização confirma que o modelo foi capaz de identificar estruturas relevantes no conjunto de dados, mesmo diante da elevada complexidade e subjetividade presente nas reviews textuais analisadas.

4.5. COMPARAÇÃO COM BASELINES

Embora o projeto não tenha implementado modelos baseline tradicionais, como sistemas de recomendação aleatórios, baseados em popularidade ou algoritmos supervisionados, foi possível realizar uma comparação conceitual entre a abordagem proposta e métodos mais simples de recomendação.

Modelos baseados exclusivamente em popularidade tendem a recomendar apenas os medicamentos mais avaliados ou com maiores médias de nota, sem considerar características específicas das avaliações dos usuários. Já abordagens aleatórias não utilizam qualquer critério de similaridade, resultando em recomendações pouco relevantes.

O sistema desenvolvido neste projeto diferencia-se dessas abordagens por utilizar técnicas de clusterização capazes de identificar padrões de comportamento entre medicamentos e avaliações. Dessa forma, o modelo consegue agrupar itens semelhantes considerando múltiplas variáveis simultaneamente, como notas atribuídas, frequência de avaliações e características presentes nos reviews textuais.

Além disso, a utilização de técnicas de mineração de dados permitiu gerar agrupamentos mais coerentes e interpretáveis, aumentando o potencial de personalização das recomendações.

Mesmo sem a implementação de algoritmos mais avançados, os resultados obtidos demonstram que o modelo desenvolvido apresenta maior capacidade analítica em relação a abordagens simplificadas, principalmente devido à identificação de padrões complexos presentes na base de dados.

4.6. DISCUSSÃO DOS RESULTADOS

Os resultados obtidos ao longo do desenvolvimento do sistema de recomendação demonstram que a utilização de técnicas de aprendizado de máquina aplicadas a avaliações de medicamentos possui elevado potencial para geração de informações relevantes e identificação de padrões de comportamento dos usuários.

A aplicação do algoritmo K-Means permitiu segmentar os medicamentos em grupos com características semelhantes, considerando não apenas as avaliações numéricas atribuídas pelos usuários, mas também informações derivadas das reviews textuais presentes na base de dados. Essa abordagem possibilitou identificar relações estatísticas relevantes entre medicamentos, comportamento dos usuários e padrões de satisfação relacionados aos tratamentos analisados.

Os agrupamentos gerados apresentaram coerência significativa, especialmente após a aplicação das etapas de pré-processamento, padronização e redução de dimensionalidade. O uso do Método do Cotovelo permitiu definir uma quantidade adequada de clusters, enquanto o índice Silhouette Score demonstrou que os agrupamentos possuíam separação moderada e consistência interna satisfatória para uma prova de conceito acadêmica.

Além disso, a utilização da técnica PCA contribuiu de maneira importante para a interpretação visual dos resultados, permitindo observar a distribuição dos clusters e identificar padrões de proximidade e sobreposição entre os grupos formados pelo algoritmo.

Outro aspecto relevante observado foi a capacidade do modelo em trabalhar com dados altamente subjetivos. Diferentemente de sistemas tradicionais que utilizam apenas informações numéricas, o projeto explorou avaliações textuais escritas pelos usuários, permitindo incorporar informações qualitativas relacionadas à experiência dos pacientes com os medicamentos.

Essa característica torna o sistema mais próximo de aplicações reais utilizadas em plataformas modernas de recomendação, nas quais opiniões, comentários e experiências dos usuários possuem grande relevância para geração de recomendações mais contextualizadas e personalizadas.

Durante a análise dos resultados, observou-se que medicamentos pertencentes ao mesmo cluster frequentemente apresentavam padrões semelhantes relacionados a:

- Nível de satisfação dos usuários;

- Frequência de avaliações;
- Popularidade dos medicamentos;
- Quantidade de votos úteis nas reviews;
- Similaridade textual entre comentários;
- Tendências de avaliações positivas ou negativas.

Esses resultados indicam que o modelo foi capaz de identificar estruturas relevantes no conjunto de dados, demonstrando que técnicas de clusterização podem ser aplicadas de forma eficiente em bases relacionadas à saúde digital.

Entretanto, algumas limitações também foram identificadas durante o desenvolvimento do projeto.

Uma das principais limitações está relacionada à subjetividade das avaliações presentes na base de dados. Como as reviews foram escritas por diferentes usuários, fatores individuais como percepção de eficácia, tolerância a efeitos colaterais e expectativas pessoais podem influenciar diretamente as notas atribuídas aos medicamentos.

Além disso, foi observada certa sobreposição entre alguns clusters no gráfico PCA, indicando que determinados medicamentos compartilham características semelhantes e podem apresentar padrões próximos de comportamento. Esse fenômeno é relativamente comum em problemas de clusterização envolvendo dados reais e heterogêneos.

Outra limitação importante refere-se ao problema conhecido como *cold start*, comum em sistemas de recomendação. Medicamentos com poucas avaliações ou baixa quantidade de reviews possuem menor representatividade estatística, dificultando a capacidade do modelo em identificar padrões confiáveis para esses itens.

Também é importante destacar que o algoritmo K-Means apresenta limitações naturais relacionadas ao formato dos agrupamentos, uma vez que assume clusters aproximadamente esféricos e depende diretamente da escolha prévia do número de grupos. Dessa forma, modelos mais avançados poderiam gerar resultados ainda mais precisos em aplicações futuras.

Apesar dessas limitações, os resultados obtidos demonstram que o sistema desenvolvido apresentou desempenho satisfatório em relação aos objetivos propostos no projeto. O modelo foi capaz de:

- Identificar padrões relevantes entre medicamentos;
- Gerar agrupamentos coerentes;

- Facilitar a interpretação visual dos dados;
- Explorar informações qualitativas presentes nas reviews;
- Demonstrar viabilidade prática de sistemas de recomendação aplicados à saúde.

Além disso, o projeto evidenciou o potencial da integração entre mineração de dados, aprendizado de máquina e processamento de linguagem natural em aplicações voltadas à análise de comportamento de usuários e apoio à decisão em saúde digital.

Os resultados obtidos também abrem possibilidades para futuras melhorias, incluindo:

- Utilização de modelos supervisionados de recomendação;
- Aplicação de embeddings semânticos;
- Implementação de técnicas de Deep Learning;
- Uso de algoritmos híbridos de recomendação;
- Análise de sentimentos aplicada às reviews;
- Integração com sistemas clínicos reais.

Dessa forma, a discussão dos resultados demonstra que o sistema desenvolvido não apenas atingiu os objetivos propostos, mas também apresentou potencial significativo para evolução em aplicações futuras mais robustas e inteligentes no contexto da saúde digital.

CONCLUSÃO

O desenvolvimento deste projeto permitiu demonstrar a aplicação prática de técnicas de aprendizado de máquina, mineração de dados e análise exploratória em um sistema de recomendação voltado para avaliações de medicamentos. A proposta do trabalho consistiu em identificar padrões de comportamento nas avaliações realizadas por usuários, utilizando métodos de clusterização e processamento de dados para agrupar medicamentos com características semelhantes.

Os resultados obtidos demonstraram que o algoritmo K-Means foi capaz de gerar agrupamentos a partir das variáveis selecionadas, mas não permitiu identificar relações relevantes entre notas atribuídas, popularidade dos medicamentos e padrões presentes nas reviews textuais. A utilização do Método do Cotovelo contribuiu para definição adequada do número de clusters, enquanto o índice Silhouette Score permitiu avaliar a qualidade dos agrupamentos gerados pelo modelo.

Além disso, a aplicação da técnica PCA possibilitou reduzir a dimensionalidade dos dados e facilitar a interpretação visual dos clusters, tornando mais clara a identificação de padrões de proximidade e separação entre os grupos formados pelo algoritmo. Contudo, essa etapa falhou em demonstrar que o modelo conseguiu capturar estruturas relevantes mesmo diante da elevada complexidade e subjetividade das avaliações presentes na base de dados.

Outro aspecto importante observado durante o desenvolvimento do projeto foi o potencial da utilização de reviews textuais em sistemas de recomendação. Diferentemente de abordagens tradicionais que utilizam apenas informações numéricas, o presente trabalho teorizou e buscou demonstrar que comentários escritos pelos usuários podem fornecer informações qualitativas relevantes relacionadas à experiência dos pacientes com os medicamentos, incluindo percepção de eficácia, satisfação com o tratamento e ocorrência de efeitos colaterais.

Os resultados obtidos também evidenciaram que técnicas de aprendizado não supervisionado podem ser aplicadas de forma eficiente em problemas relacionados à saúde digital, principalmente em cenários onde não existem classificações previamente definidas ou grandes volumes de dados rotulados.

Entretanto, algumas limitações foram identificadas ao longo do projeto. A principal delas está relacionada à natureza subjetiva das avaliações realizadas pelos usuários, uma vez que fatores individuais podem influenciar diretamente as notas

atribuídas aos medicamentos. Também foram observadas regiões de sobreposição entre determinados clusters, indicando similaridade parcial entre alguns grupos de medicamentos.

Além disso, o algoritmo K-Means apresenta limitações relacionadas à dependência da escolha prévia do número de clusters e à dificuldade em lidar com agrupamentos de formatos não lineares. Outro desafio identificado foi o problema de *cold start*, comum em sistemas de recomendação, no qual medicamentos com poucas avaliações possuem menor representatividade estatística para geração de recomendações confiáveis.

Mesmo diante dessas limitações, o projeto atingiu os objetivos propostos e demonstrou a viabilidade da aplicação de inteligência artificial em sistemas de recomendação voltados à área da saúde. O modelo desenvolvido apresentou capacidade de identificar padrões relevantes, organizar medicamentos em grupos semelhantes e gerar informações úteis para análise do comportamento dos usuários.

Como possibilidades para trabalhos futuros, destacam-se:

- Implementação de modelos supervisionados de recomendação;
- Aplicação de algoritmos híbridos;
- Utilização de técnicas de Deep Learning;
- Uso de embeddings semânticos para análise textual;
- Implementação de análise de sentimentos nas reviews;
- Integração com bases clínicas reais;
- Desenvolvimento de sistemas personalizados para pacientes.

Dessa forma, conclui-se que a integração entre aprendizado de máquina, mineração de dados e processamento de linguagem natural possui grande potencial para aplicações em saúde digital, especialmente em sistemas inteligentes capazes de auxiliar usuários na análise e recomendação de medicamentos com base em experiências reais compartilhadas em plataformas digitais.

REFERÊNCIAS

- AGGARWAL, Charu C. *Recommender Systems: The Textbook*. Cham: Springer, 2016.
- BURKE, Robin. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331–370, 2002.
- DREW, Daniel A.; KELLOGG, Megan D.; LEE, Hyun J. Machine learning in medicine: A practical introduction. *New England Journal of Medicine*, 2020.
- FLORIDI, Luciano et al. AI4People—An ethical framework for a good AI society. *Minds and Machines*, v. 28, p. 689–707, 2018.
- GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. Cambridge: MIT Press, 2016.
- HAN, Jiawei; KAMBER, Micheline; PEI, Jian. *Data Mining: Concepts and Techniques*. 3. ed. Waltham: Morgan Kaufmann, 2012.
- HARPER, F. Maxwell; KONSTAN, Joseph A. The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems*, v. 5, n. 4, 2016.
- HERLOCKER, Jonathan L. et al. Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, v. 22, n. 1, 2004.
- JESSICA LI. KUC Hackathon Winter 2018 – Drug Review Dataset. Kaggle, 2018.
- JOLLIFFE, Ian T. *Principal Component Analysis*. 2. ed. New York: Springer, 2002.
- MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.
- MINER, Gary et al. *Practical Text Mining and Statistical Analysis for Non-structured Text Data Applications*. Academic Press, 2012.
- ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). *Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável*. Nova York: ONU, 2015.
- ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Promoting rational use of medicines: core components*. Geneva: WHO, 2002.
- RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. *Recommender Systems Handbook*. 2. ed. Boston: Springer, 2015.
- ROUSSEEUW, Peter J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.
- SARWAR, Badrul et al. Item-based collaborative filtering recommendation algorithms. In: *Proceedings of the 10th International World Wide Web Conference*. 2001.

SHICKEL, Benjamin et al. Deep learning in healthcare: A review. *Journal of Biomedical Informatics*, v. 75, p. 3–21, 2017.

TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. *Introduction to Data Mining*. Boston: Pearson, 2005.